



Efeito casa (house effects): metodologia, prova de reprodução e robustez

Placar das Pesquisas — matriz instituto $\times$ candidato, corrida presidencial, 1º turno

Base: votos válidos · campo comparável.

Documento técnico verificável · A média que você pode refazer · 2026

Documento técnico. Objetivo: demonstrar, de forma verificável e independente, que a matriz "EFEITO CASA" publicada em `/institutos` é (i) matematicamente bem definida, (ii) calculada por uma regra pública e sem parâmetros ocultos, e (iii) reproduzível por qualquer pessoa a partir dos dados brutos. Todos os números foram gerados por uma **segunda implementação, escrita do zero em Python** a partir da definição matemática (`reproduzir_efeito_casa.py`) — não pelo código do site.

Notas de versão (endurecimento após revisão). O método passou por escrutínio cético e foi endurecido em três frentes; todas incorporadas aqui. Passar por esse escrutínio e sobreviver **fortalece** o documento — onde uma célula deixou de ser significativa ou saiu da matriz, dizemos.

1. **Votos válidos** — os resíduos são calculados sobre votos válidos, não sobre a base bruta, isolando o viés por candidato do artefato de alocação de indecisos.
2. **Campo comparável** — uma pesquisa só entra no cálculo se testa os dois primeiros colocados atuais e tem elenco ≥ 5 candidatos; isso remove o artefato de **agregação de cenários** (hipotéticos reduzidos e cenários de eras passadas inflam o % de um minoritário). Por isso a coluna do **Marçal saiu** — não há base comparável, não porque escondemos. Ver [§4](#).
3. **Estatística honesta** — significância pelo **t de Student** $t(df)$ (não $|ef| > 2EP$) e erro-padrão também por **bootstrap de blocos** (corrige a autocorrelação).

Fonte dos dados: `data/polls.json` (185 pesquisas presidenciais de 1º turno; **104** comparáveis). SHA-256 e data no [Apêndice](#).

1. Sumário executivo

O **efeito casa** de um instituto J para um candidato c é o quanto, em média, as pesquisas de J **desviam da média das demais pesquisas** para aquele candidato, **medido sobre votos válidos, dentro do campo comparável** (a corrida atual e cheia), em pontos percentuais (p.p.). Positivo = J tende a **superestimar** c ; negativo = **subestimar**.

- **É legítimo e é técnica padrão.** "House effects" é instrumento consagrado de agregadores sérios (FiveThirtyEight, The Economist, pollster ratings). Ver [§10](#).
- **É descritivo, não acusatório.** Um desvio sistemático pode refletir metodologia legítima (desenho amostral, modo de coleta, tratamento de indecisos), não fraude.
- **Comparamos só onde a comparação é honesta.** Duas escolhas de escopo evitam artefatos que não são viés de casa: **votos válidos** (base comum entre institutos, [§3.2](#)) e **campo comparável** (mesmo elenco, [§4](#)). Ambas mudam materialmente a matriz: **AtlasIntel×Lula cai de +10,5 (bruto, todos os cenários) para +3,2** (válidos, campo comparável), e o **Marçal deixa de ter coluna** (só 3 pesquisas o testam no campo cheio, em 3 institutos distintos — base insuficiente).
- **É reproduzível.** Uma implementação independente reproduz a matriz do site com **100% de concordância célula a célula** (80/80) contra o site ao vivo. Ver [§7](#).
- **É honesto quanto à incerteza.** Cada célula traz erro-padrão (corrigido por autocorrelação) e teste t . Os efeitos **robustos** concentram-se nos dois institutos com maior base comparável — **AtlasIntel** (Lula +3,2, Renan +2,9, Caiado/Zema -1,8, Flávio -1,6) e **Gerp** (Flávio +5,3, Lula -3,3, Caiado -1,5). Efeitos de amostra pequena (ex.: Futura×Flávio, Paraná×Flávio) são apenas **sugestivos**.

2. Intuição

Institutos diferentes, medindo o mesmo eleitorado na mesma semana, publicam números sistematicamente diferentes. Isso não é aleatório: decorre de escolhas metodológicas estáveis — estratificação da amostra, modo de coleta, tratamento de indecisos, ponderação por voto anterior. Cada escolha empurra as estimativas de um instituto numa direção mais ou menos constante. O efeito casa **isola essa assinatura**: para cada candidato, comparamos o número do instituto com o "consenso" das outras pesquisas contemporâneas.

Mas a comparação só é honesta se os dois lados falam a mesma língua. Dois cuidados:

- **Mesma base** (votos válidos): institutos deixam frações diferentes de indecisos fora dos nomes; sem converter, quem "força" a escolha parece superestimar todo mundo.

- **Mesmo campo** (campo comparável): o % de um candidato depende de **quem mais está na lista**. Num cenário hipotético de 3 nomes, o mesmo Marçal marca 27,7% (Quaest, set/2024); no campo cheio de 8–13 nomes, marca 2–5%. Comparar um contra o outro não mede viés de casa — mede tamanho de campo.

Exemplo real (dados na §6): no campo comparável e em válidos, a AtlasIntel pôs Lula em 48,8; 49,6; 48,6... enquanto o consenso das demais rodava $\approx 43\text{--}46$ — um desvio de $\approx +3,2$ p.p., estável ao longo de 10 pesquisas. Isso é um efeito casa robusto.

3. Definição formal

3.1 Notação

- J — instituto. c — candidato. p — pesquisa. d — data.
- $\text{\texttt{\text{data}}}(p) = \text{\texttt{\text{fieldwork_end}}}, \text{\texttt{\text{published_date}}}, \text{\texttt{\text{fieldwork_start}}}$ (primeiro campo não-nulo; regra `pollDate`).
- $\text{chave}(c)$ — nome do candidato normalizado (NFD, sem acentos, minúsculas, *trim*) para casar o mesmo candidato entre pesquisas (`candKey`).

3.2 Votos válidos — a base de medição

Cada pesquisa é convertida ao cut de **votos válidos** antes de qualquer conta:

$$D(p) = \sum_c x_p^{\text{bruto}}(c) + \text{outros}_p, \quad x_p(c) = x_p^{\text{bruto}}(c) \cdot \frac{100}{D(p)}.$$

Regra `validDenominator/toBasis` de `src/lib/validos.ts` (converter cada pesquisa, depois mediar). Daqui em diante $x_p(c)$ é o percentual **em votos válidos**.

3.3 A janela do site — `selectWindow`

O consenso usa a mesma média móvel do resto do site. Dado um conjunto ordenado do mais recente ao mais antigo (empate de data desfeito pelo `id`), a janela W toma as `LATEST_N = 10` pesquisas mais recentes, no máximo `MAX_PER_POLLSTER = 2` por instituto (com piso de *backfill* `MIN_POLLS = 3`). O teto impede que uma casa prolífica carregue a média com o próprio efeito casa.

3.4 O consenso *leave-one-out* — `asOfAverage`

O consenso para c na data d , **excluindo J** e **sobre o campo comparável** (§4), é a média dos valores de c na janela aplicada às pesquisas de $\mathcal{C}_{-J}$ publicadas até d :

$$\bar{x}_{-J}(c, d) = \frac{1}{|V|} \sum_{p \in V} x_p(c), \quad V = \{p \in W(\text{selectWindow}) : x_p(c) \text{ existe}\}.$$

Indefinido se $|V| < \text{MIN_CONSENSUS_POLLS} = 3$.

3.5 Resíduo, efeito casa e magnitude

Resíduo $r_p(c) = x_p(c) - \bar{x}_{-J}(c, d)$. O efeito casa é a média dos resíduos:

$$\text{efeito}(J, c) = \text{round}_1\left(\frac{1}{n} \sum_{i=1}^n r_i(c)\right)$$

Publicada só se $n \geq \text{MIN_OBS_PER_CELL} = 2$. A **magnitude** ($= \text{round}_1(\text{média}_c |\text{efeito}(J, c)|)$ sobre as células preenchidas) ordena as linhas. Instituto entra com $\geq \text{MIN_POLLS_PER_POLLSTER} = 3$ pesquisas **comparáveis**.

3.6 As colunas

As colunas são os $\text{MAX_COLUMNS} = 6$ candidatos registrados no TSE de maior média no site (válidos), **menos as colunas 100% vazias** após o filtro de campo comparável. Hoje sobram **5: Lula, Flávio Bolsonaro, Renan Santos, Ronaldo Caiado, Zema** — o Marçal (6º por média) é podado por falta de base comparável (§4).

3.7 Parâmetros (confirmados lendo o código)

Parâmetro	Valor	Origem	Papel
LATEST_N	10	average.ts	tamanho da janela (nº de pesquisas)
MAX_PER_POLLSTER	2	average.ts	teto de pesquisas por instituto na janela
MIN_POLLS	3	average.ts	piso de <i>backfill</i>
MIN_POLLS_PER_POLLSTER	3	houseEffects.ts	mínimo de pesquisas comparáveis do instituto
MIN_OBS_PER_CELL	2	houseEffects.ts	mínimo de resíduos por célula
MIN_CONSENSUS_POLLS	3	houseEffects.ts	mínimo de pesquisas de outros no consenso
MAX_COLUMNS	6	houseEffects.ts	teto de colunas antes da poda
MIN_FIELD	5	houseEffects.ts	elenco mínimo (campo comparável)
base	válidos	houseEffects.ts	<code>pollsFor(...).map(toBasis(p, "validos"))</code>

4. Campo comparável (o artefato de agregação de cenários)

Institutos testam um candidato minoritário em **campos de tamanhos muito diferentes**: cenários hipotéticos reduzidos (2–4 nomes), cenários de eras passadas (ex.: Lula×Bolsonaro, antes de o Flávio entrar) e o campo cheio atual (8–13 nomes). Em votos válidos, **o % de um candidato incha conforme o campo encolhe** — não porque o instituto tem viés, mas porque há menos gente dividindo os 100%.

O caso do **Marçal** é o exemplo canônico. O mesmo candidato, em votos válidos:

Fonte	Campo	Marçal (válidos)
Quaest (29/09/2024)	3 nomes (Lula, Marçal, Tarcísio)	27,7%
Gerp (06/12/2025)	7 nomes	4,5%
Veritá (20/08/2026)	12 nomes	5,4%
Datafolha (20/08/2026)	13 nomes	2,2%

Agregar esses números produziria um "efeito casa" fantasma (na base bruta, sem este filtro, o Marçal aparecia com $-8,7$) que mede **composição de cenário**, não viés por candidato. Pior: uma dessas pesquisas de campo pequeno também **contamina o consenso** contra o qual todos os outros são medidos.

A regra (campo comparável). Uma pesquisa só entra no cálculo — como linha e como consenso — se:

$$|\text{results}(p)| \geq \text{MIN_FIELD} = 5$$

campo cheio

e

$$\{\hat{\text{âncora}}_1, \hat{\text{âncora}}_2\} \subseteq \text{results}(p)$$

corrida atual

onde as **âncoras** são os dois primeiros colocados atuais por média (**Lula** e **Flávio**). Exigir ambas restringe à corrida de hoje; exigir elenco ≥ 5 exclui os hipotéticos reduzidos. Uma coluna que fica **100% vazia** depois disso é **podada** — um candidato sem nenhuma célula de base comparável não vira uma coluna inteira de "—".

Efeito da regra. Das 185 pesquisas presidenciais, **104 são comparáveis** (81 excluídas; 13 têm menos de 5 nomes, as demais não testam ambas as âncoras). O Marçal é testado em 30 pesquisas, mas **só 3** no campo comparável — e em 3 institutos distintos (Datafolha, Veritá, Gerp), então nenhum atinge as 2 observações mínimas por célula: a coluna é podada. **Isto é uma força, não uma omissão:** medimos só onde a comparação é honesta, e dizemos abertamente que o Marçal não tem base comparável suficiente.

Enquadramento honesto. A ausência da coluna do Marçal **não** é juízo sobre ele nem sobre quem o pesquisa — é a constatação de que, no campo cheio da corrida atual, ainda há poucas medições dele para separar viés de ruído.

5. Por que *leave-one-out* e os portões de robustez

Leave-one-out. Se o consenso incluísse as pesquisas do próprio *J*, a medição estaria contaminada por auto-comparação e o efeito seria **encolhido**, tanto mais quanto mais o instituto pesquisa. Se *J* responde por fração *w* da janela com desvio δ , um consenso **com** *J* mediria $\approx (1 - w) \delta$. Excluir *J* devolve o δ cheio.

Portões (cada um evita um modo de falha): ≥ 3 pesquisas comparáveis por instituto (evita "efeitos" de 1–2 pesquisas); ≥ 2 observações por célula (um resíduo não é tendência); ≥ 3 pesquisas de outros no consenso (não medir contra uma média de 1); teto de 2 por instituto na janela (nenhuma casa domina o consenso); campo comparável

- top-6 registradas com poda (§4).

Constraint da casa: um instituto ausente da matriz (menos de 3 pesquisas comparáveis, ou nenhuma célula com ≥ 2 observações) **não recebe juízo algum**.

6. Derivação passo a passo: AtlasIntel $\times$ Lula

No campo comparável, a AtlasIntel tem **10 pesquisas** (todas do campo cheio, de dez/2025 em diante — os cenários reduzidos e antigos ficaram de fora). Em votos válidos, cada uma: o valor da AtlasIntel para Lula, o consenso das **demais** naquela data e o resíduo.

Data	Campo	Atlas · Lula	Consenso sem Atlas	Resíduo
2025-12-10	7	48,83	43,821	+5,007
2025-12-15	6	48,83	43,345	+5,483
2025-12-15	7	48,83	43,345	+5,483
2026-01-20	8	49,59	43,170	+6,420
2026-02-24	7	48,11	45,392	+2,718
2026-03-23	7	46,35	46,258	+0,091
2026-04-27	12	44,47	44,277	+0,190
2026-05-18	7	48,60	43,304	+5,300
2026-06-30	13	46,86	46,041	+0,821
2026-07-27	11	45,68	44,790	+0,887

Exemplo de uma linha (2026-01-20, resíduo +6,420). Em votos válidos, num campo de 8 nomes, a AtlasIntel pôs Lula em 49,59. O consenso sem AtlasIntel é a média de Lula nas 10 pesquisas comparáveis mais recentes de **outros** institutos até 2026-01-20 (máx. 2 por casa) — 43,170. Resíduo = $49,59 - 43,170 = +6,42$.

Fechamento. Média dos 10 resíduos = +3,240 $\Rightarrow$ efeito = +3,2 p.p., exatamente o valor publicado. Desvio-padrão $s = 2,55$; EP ingênuo $s/\sqrt{10} = 0,81$; EP honesto por bootstrap de blocos = 0,91; $t = 3,24/0,91 \approx 3,6$ (df = 9) — significativo a 95% ($t_{9,0,975} = 2,26$). (Trajetória do mesmo número: +10,5 na base bruta com todos os cenários; +5,6 em válidos com todos os cenários; +3,2 em válidos e campo comparável. Cada correção removeu um artefato de comparação, e o efeito real — a AtlasIntel põe Lula acima dos pares — permanece e segue significativo.)

7. Resultados completos e fidelidade

Matriz reproduzida (Python independente, `data/polls.json`, votos válidos, campo comparável). Célula: efeito em p.p. (≈ 0 se $|\text{efeito}| < 0,5$; "—" sem base). Entre parênteses, o **EP honesto** (bootstrap de blocos quando $n \geq 6$, senão $s/\sqrt{n}$) e o n ; * = **significativo a 95%** por $t(\text{df})$. " n pesq." é a contagem de pesquisas **comparáveis** do instituto. 104 pesquisas comparáveis; 16 institutos; 80 células preenchidas.

Instituto (n)	Lula	Flávio	Renan	Caiado	Zema
Gerp (11)	−3,3* (0,4 · 10)	+5,3* (1,0 · 10)	−0,7 (0,4 · 9)	−1,5* (0,4 · 10)	−0,7 (0,4 · 10)
AtlasIntel (10)	+3,2* (0,9 · 10)	−1,6* (0,4 · 10)	+2,9* (0,5 · 7)	−1,8* (0,3 · 10)	−1,8* (0,5 · 10)
Futura (5)	−2,3 (1,2 · 5)	+5,7 (3,0 · 5)	≈0	+1,0 (1,2 · 4)	+0,9 (0,6 · 5)
Alfa/TMC (3)	−0,5 (1,8 · 3)	−4,1* (0,2 · 3)	−1,4* (0,3 · 3)	+1,8 (1,1 · 3)	+2,7 (0,8 · 3)
MDA (3)	+4,4* (0,2 · 3)	−3,5* (0,6 · 3)	−1,1 (0,6 · 3)	≈0	≈0
Paraná Pesquisas (3)	+1,2 (1,5 · 3)	+6,8 (1,9 · 3)	−0,9* (0,2 · 3)	≈0	≈0
Veritá (4)	−3,2* (0,6 · 4)	+3,5* (0,6 · 4)	≈0	−1,3* (0,1 · 4)	+0,5 (1,3 · 4)
Data Index (3)	+3,2* (0,1 · 3)	−2,1 (0,8 · 3)	−0,6 (0,3 · 3)	+1,8 (0,4 · 3)	≈0
Real Time Big Data (6)	≈0	−1,1 (1,5 · 6)	+1,7 (1,1 · 5)	+1,5* (0,5 · 4)	≈0
100% Cidades Part. (3)	−1,2 (2,7 · 3)	+2,3 (1,1 · 3)	−0,7 (0,5 · 3)	≈0	≈0
Ideia (6)	≈0	+1,6 (1,1 · 6)	−0,7 (0,4 · 6)	+1,4 (0,9 · 4)	≈0
Vox (5)	≈0	≈0	−1,3* (0,3 · 5)	+1,6 (0,7 · 5)	≈0
PoderData (5)	−1,6* (0,5 · 5)	+0,8 (0,7 · 5)	≈0	−0,7* (0,1 · 5)	≈0
Quaest (11)	+1,2 (0,9 · 10)	≈0	≈0	−0,7 (0,7 · 9)	−0,5 (0,3 · 10)
Nexus (10)	−0,7 (0,3 · 10)	+0,6 (0,6 · 10)	≈0	≈0	≈0
Datafolha (8)	≈0	−1,4 (0,7 · 7)	≈0	≈0	≈0

(célula: efeito* (EP · n); * = signif. 95% por t(df). "≈0" quando |efeito|<0,5.)

7.1 Fidelidade: a matriz reproduz o site — 100%

verificar_fidelidade.py é uma **implementação separada e autossuficiente** do algoritmo (não importa reproduzir_efeito_casa.py), que baixa o HTML **ao vivo** de <http://localhost:3000/institutos>, o parseia como fonte da verdade e compara célula a célula:

Comparação	Concordância
Implementação independente × site AO VIVO (válidos + campo comparável)	80/80 = 100,0%

Nenhuma célula diverge. **Ordem das linhas:** idêntica exceto por **uma troca de duas linhas adjacentes** — Paraná Pesquisas e MDA, **empatadas** em magnitude (1,9) e n° de pesquisas (3). Quando ambos empatam, o desempate cai na ordem de aparição dos registros, que difere entre o polls.json (o export) e o store NDJSON que o site lê. É cosmético (duas linhas de mesma magnitude trocam de lugar) e **não afeta nenhum valor de célula**; alimentada com o store, a implementação reproduz também a ordem exata do site.

8. Incerteza e significância

Para cada célula reportamos dois erros-padrão da média dos resíduos: o **ingênuo** $s/\sqrt{n}$ e o de **bootstrap de blocos móveis** (bloco $\approx n^{1/3}$; determinístico dado o seed), que capta a **autocorrelação** dos resíduos do mesmo (J, c) — janelas de consenso sobrepostas e opinião com tendência. O EP ingênuo subestima; usamos o **EP honesto** (bloco quando $n \geq 6$, senão $s/\sqrt{n}$). Uma célula é **significativa a 95%** se, no teste t bicaudal de uma amostra (H_0 : média = 0), $|r|/\text{EP} > t_{\{\text{df}, 0.975\}}$, $\text{df}=n-1$ — corrige o critério plano $|ef| > 2\text{EP}$ (para $n = 3$ o multiplicador é 4,30, não 2).

Efeitos robustos (base comparável grande, $n \geq 6$, significativos com EP honesto):

Instituto $\times$ candidato	Efeito	EP honesto	n	t
Gerp $\times$ Flávio	+5,3	0,96	10	5,6
Gerp $\times$ Lula	−3,3	0,44	10	7,5
AtlasIntel $\times$ Lula	+3,2	0,91	10	3,6
AtlasIntel $\times$ Renan	+2,9	0,52	7	5,6
AtlasIntel $\times$ Caiado	−1,8	0,33	10	5,6
AtlasIntel $\times$ Zema	−1,8	0,55	10	3,3
AtlasIntel $\times$ Flávio	−1,6	0,41	10	3,9
Gerp $\times$ Caiado	−1,5	0,36	10	4,1

Os robustos concentram-se nos **dois institutos com maior base comparável** (Gerp e AtlasIntel, 10 pesquisas cada) — o esperado, já que o campo comparável reduziu a base da maioria dos institutos a 3–5 pesquisas.

Efeitos apenas sugestivos (amostra pequena, $n \leq 5$: o t pode passar, mas 3–4 resíduos produzem EP artificialmente minúsculo e não sustentam magnitude precisa): MDA $\times$ Lula (+4,4, $n = 3$), Alfa/TMC $\times$ Flávio (−4,1, $n = 3$), Veritá $\times$ Flávio/Lula (+3,5/−3,2, $n = 4$), MDA $\times$ Flávio (−3,5, $n = 3$), Data Index $\times$ Lula (+3,2, $n = 3$). O **signal** é informativo; a magnitude, não. **Não** citamos contagens do tipo "20 EP": com $n = 3$ isso é estatisticamente vazio.

Grandes, mas NÃO significativos a 95%: Futura $\times$ Flávio +5,7 ($n = 5$, EP 3,0, $t = 1,9 < 2,78$) e **Paraná $\times$ Flávio** +6,8 ($n = 3$, $t \approx 3,6 < 4,30$) — sinais a acompanhar, não efeitos estabelecidos. (Ambos tinham base bem maior antes do campo comparável; com o elenco cheio, a base encolheu e a incerteza cresceu — corretamente.)

Leitura. Os destaques — Gerp (Flávio +5,3, Lula −3,3) e AtlasIntel (Lula +3,2, Renan +2,9, Caiado/Zema −1,8) — são robustos em válidos, campo comparável e EP honesto. As muitas células ≈ 0 são o esperado de institutos sem viés detectável para aquele candidato: a matriz distingue viés de ruído.

9. Robustez / sensibilidade

Recalculamos os efeitos robustos variando a janela ($\text{LATEST_N} \in \{8, 10, 12\}$), removendo o teto por instituto e endurecendo o campo mínimo ($\text{MIN_FIELD} = 6$). Se fossem artefato de um parâmetro, mudariam de sinal ou de ordem de grandeza. Não mudam:

Efeito	N=8	N=10 (site)	N=12	sem teto	campo ≥ 6
AtlasIntel $\times$ Lula	+3,2	+3,2	+3,1	+3,2	+4,3
AtlasIntel $\times$ Flávio	−1,9	−1,6	−1,3	−1,5	−2,0
AtlasIntel $\times$ Renan	+2,9	+2,9	+3,0	+2,9	+2,9
Gerp $\times$ Lula	−3,2	−3,3	−3,4	−3,3	−2,7
Gerp $\times$ Flávio	+5,0	+5,3	+5,3	+5,4	+5,1
Gerp $\times$ Caiado	−1,4	−1,5	−1,4	−1,5	−1,6

Sinal e ordem de grandeza intactos nas cinco configurações; variação célula a célula $\leq 1,1$ p.p. A matriz não depende do valor exato de `LATEST_N`, do teto por instituto nem do limiar de campo (desde que exclua os hipotéticos reduzidos).

10. Comparação com o estado da arte

Medir e publicar "house effects" é prática **padrão** e amplamente aceita: **FiveThirtyEight** publica *house effects* e *pollster ratings* há mais de uma década; **The Economist** e outros modelos estimam desvios de instituto como parte natural do modelo (frequentemente bayesiano hierárquico); a literatura de *poll aggregation* formaliza o conceito como *pollster fixed effects*. A boa prática de **restringir a cenários comparáveis** (mesmo elenco) antes de comparar é reconhecida — é o que o campo comparável faz. Nosso método é a versão **transparente e reprodutível** desse instrumento: regra única, pública, parâmetros à vista, base e escopo declarados, código auditável.

11. Limitações honestas

- **Base e campo estreitam a amostra.** Válidos + campo comparável removem dois artefatos reais, mas ao preço de **reduzir a base**: a maioria dos institutos fica com 3–5 pesquisas comparáveis, e só dois (Gerp, AtlasIntel) sustentam efeitos plenamente robustos. É a troca certa — preferimos poucos números confiáveis a muitos contaminados —, mas o leitor deve saber que a matriz hoje é, sobretudo, forte sobre esses dois institutos.
- **Marçal (e outros minoritários) sem coluna.** Não é juízo; é base comparável insuficiente. À medida que mais institutos testarem o campo cheio, a coluna pode voltar.

- **Alocação de indecisos.** Medir em válidos remove o artefato de base, mas *quanto* de indeciso cada instituto distribui é, ele próprio, um efeito casa que esta matriz por candidato deliberadamente não exhibe.
- **Sem a dimensão modo de coleta.** Não separamos presencial/telefone/online, fonte legítima de efeito casa; parte do que atribuímos ao instituto pode ser do **modo**.
- **Média vs. mediana; EP para n pequeno.** Usamos a média dos resíduos; para $n \leq 5$ nenhuma estimativa de EP é confiável e rebaixamos essas células a "sugestivas".
- **Ausência $\neq$ juízo; descritivo, não causal.** Um instituto fora da matriz não recebe avaliação. Um efeito casa não diz que o instituto está errado — a "verdade" só se conhece na eleição; diz que ele desvia sistematicamente da média dos pares, em votos válidos e no campo comparável.

Apêndice de reprodutibilidade

Endurecimento após revisão (25/08/2026). O método foi revisto em três rodadas — **votos válidos** (isola o viés por candidato), **campo comparável** (remove o artefato de agregação de cenários; poda o Marçal por falta de base) e **estatística honesta** ($t(df) + EP$ por bootstrap de blocos). Os grandes efeitos sobreviveram em sinal e ordem de grandeza; onde uma célula deixou de ser significativa (Futura×Flávio, Paraná×Flávio) ou saiu da matriz (Marçal), o texto o diz.

Como rodar (Python 3, apenas biblioteca padrão — `json`, `statistics`, `math`, `random`, `urllib`):

```
# a partir da raiz do worktree pdp-staging (onde está data/polls.json):
python3 reproduzir_efeito_casa.py data/polls.json
# → imprime a matriz (válidos, campo comparável) e grava matriz_efeito_casa.csv com:
#   instituto, n_pesquisas, candidato, efeito, n_observacoes,
#   erro_padrao, erro_padrao_bloco, gl, t, significativo_95

# verificação de fidelidade INDEPENDENTE contra o site ao vivo:
python3 verificar_fidelidade.py data/polls.json
# → CONCORDÂNCIA (implementação independente vs site): 80/80 = 100,0%
```

Arquivos entregues (nesta pasta):

- `reproduzir_efeito_casa.py` — reimplementação independente (stdlib); válidos, campo comparável, $t(df)$ e EP por bootstrap de blocos; gera a matriz e o CSV.
- `verificar_fidelidade.py` — 3ª implementação autossuficiente (não importa a anterior); parseia o HTML ao vivo de `/institutos`, aplica o campo comparável e compara célula a célula.

- `matriz_efeito_casa.csv` — matriz completa com efeito, n, EP ingênuo, EP por bloco, gl, t e veredito de significância 95%.
- `site_efeito_casa.json` — snapshot da tabela publicada (válidos + campo comparável), usado como *fallback*.
- `efeito-casa-metodologia.md` — este documento.

Fonte dos dados. Curadoria de fontes públicas (agregador Poder360, páginas de pesquisas da Wikipédia) reconciliada com o **registro de pesquisas do TSE** (Dados Abertos — PesqEle 2026). Cada pesquisa carrega seu `tse_registration` e `integra_url`.

Proveniência do arquivo usado.

- Arquivo: `data/polls.json`
- SHA-256: `885128c7f722def57e63a28a8855e35cc98323edb45976b3bbf5ae25eb949911`
- `generated_at` do store: `2026-08-23T12:59:35Z` (schema v2). As três correções foram **no código** (`houseEffects.ts`), não nos dados — o SHA do `polls.json` permanece o mesmo dos rascunhos anteriores.
- Disputa: `race="presidente", state=null, round=1` — 185 pesquisas (104 comparáveis).
- Relatório gerado em: **2026-08-25**. Python 3.9.6.

```
shasum -a 256 data/polls.json
# 885128c7f722def57e63a28a8855e35cc98323edb45976b3bbf5ae25eb949911
```

Qualquer pessoa com o `polls.json` deste SHA e os dois scripts obtém, sem dependências externas, exatamente a matriz aqui documentada.



PLACAR
DAS **PESQUISAS**

A MÉDIA QUE REVELA O PADRÃO