

# Efeito casa (house effects): metodologia, prova de reprodução e robustez

**Placar das Pesquisas — matriz instituto × candidato, corrida presidencial, 1º turno Base: votos válidos.**

Documento técnico. Objetivo: demonstrar, de forma verificável e independente, que a matriz "EFEITO CASA" publicada em `/institutos` é (i) matematicamente bem definida, (ii) calculada por uma regra pública e sem parâmetros ocultos, e (iii) reproduzível por qualquer pessoa a partir dos dados brutos. Todos os números foram gerados por uma **segunda implementação, escrita do zero em Python** a partir da definição matemática (`reproduzir_efeito_casa.py`) — não pelo código do site.

**Nota de versão (25/08/2026).** Este método foi **endurecido após revisão adversarial** por dois verificadores céticos independentes (pareceres `verificacao-adversarial-estatistica.md` e `verificacao-adversarial-reprodutibilidade.md`, mesma pasta). Três correções foram adotadas e estão incorporadas aqui: **(1)** os resíduos passam a ser calculados em **votos válidos**, não na base bruta — isolando o viés por candidato do artefato de alocação de indecisos; **(2)** a significância usa o **t de Student**  $t(df)$ , não o critério plano  $|ef| > 2EP$ ; **(3)** o erro-padrão é reportado também por **bootstrap de blocos**, que corrige a subestimação por autocorrelação. Passar por esse escrutínio e sobreviver **fortalece** o documento; onde uma célula deixou de ser significativa, dizemos.

Fonte dos dados: `data/polls.json` (185 pesquisas presidenciais de 1º turno). SHA-256 e data no [Apêndice de reprodutibilidade](#).

## 1. Sumário executivo

O **efeito casa** de um instituto  $J$  para um candidato  $c$  é o quanto, em média, as pesquisas de  $J$  **desviam da média das demais pesquisas** para aquele candidato, **medido sobre votos válidos**, em pontos percentuais (p.p.). Positivo =  $J$  tende a **superestimar**  $c$ ; negativo = **subestimar**.

- **É legítimo e é técnica padrão.** "House effects" é instrumento consagrado de agregadores sérios (FiveThirtyEight, The Economist, pollster ratings). Ver [§10](#).
- **É descritivo, não acusatório.** Um desvio sistemático pode refletir metodologia legítima (desenho amostral, modo de coleta, tratamento de indecisos), não fraude.
- **A base importa — e por isso usamos votos válidos.** Na base bruta, um instituto que "força" a escolha (deixa menos indeciso) aparece superestimando **todos** os candidatos — um artefato de composição, não viés por candidato. Converter a válidos antes de qualquer conta remove esse artefato. Fazê-lo muda materialmente a matriz (ver [§4](#)): **AtlasIntel×Lula cai de +10,5 (bruto) para +5,6 (válidos)**, e **3 células trocam de sinal**.
- **É reprodutível.** Uma implementação independente reproduz a matriz do site com **100% de concordância célula a célula** (96/96) contra o site renderizado ao vivo. Ver [§7](#).
- **É honesto quanto à incerteza.** Cada célula traz erro-padrão (inclusive corrigido por autocorrelação) e teste  $t$ . Separamos os efeitos **robustos** (ex.: AtlasIntel×Lula +5,6,  $t \approx 6,4$ ) dos apenas **sugestivos** (amostra pequena, ex.: Paraná×Flávio +5,8, que **não** é significativo a 95%).

## 2. Intuição

Institutos diferentes, medindo o mesmo eleitorado na mesma semana, publicam números sistematicamente diferentes. Isso não é aleatório: decorre de escolhas metodológicas estáveis — estratificação da amostra, modo de coleta (presencial/telefone/online), tratamento de indecisos e brancos/nulos, ponderação por voto anterior. Cada escolha empurra as estimativas de um instituto numa direção mais ou menos constante.

O efeito casa **isola essa assinatura**. Para cada candidato, comparamos o número do instituto com o "consenso" das outras pesquisas contemporâneas. Se um instituto aparece mês após mês vários pontos acima dos demais para um candidato, isso é característica do instituto, não do dia — e é o que a matriz mede.

Um exemplo real (dados na §6): em votos válidos, a AtlasIntel mediu Lula em 45,2; 46,5; 49,9; 50,9... enquanto o consenso das demais pesquisas nas mesmas datas rodava  $\approx 37\text{--}43$ . O desvio é grande e persiste por 24 pesquisas ao longo de 18 meses. Isso é um efeito casa robusto.

## 3. Definição formal

### 3.1 Notação

- $J$  — instituto.  $c$  — candidato.  $p$  — pesquisa.  $d$  — data.
- $\text{data}(p) = \text{fieldwork\_end} \vee \text{published\_date} \vee \text{fieldwork\_start}$  (primeiro campo não-nulo; regra `pollDate`).
- $\text{chave}(c)$  — nome do candidato normalizado (NFD, sem acentos, minúsculas, *trim*) para casar o mesmo candidato entre pesquisas (`candKey`).

### 3.2 Votos válidos — a base de medição

Cada pesquisa é convertida ao cut de **votos válidos** antes de qualquer conta. O denominador válido é a soma dos candidatos nomeados mais a categoria "outros"; brancos, nulos e indecisos ficam de fora (não são votos válidos):

$$D(p) = \sum_c x_p^{\text{bruto}}(c) + \text{outros}_p, \quad x_p(c) = x_p^{\text{bruto}}(c) \cdot \frac{100}{D(p)}.$$

Esta é a regra `validDenominator / toBasis` de `src/lib/validos.ts` (regra 1: **converter cada pesquisa, depois mediar** — nunca o contrário). Daqui em diante,  $x_p(c)$  denota o percentual **em votos válidos**.

### 3.3 A janela do site — `selectWindow`

O consenso usa **a mesma média móvel do resto do site**. Dado um conjunto de pesquisas ordenado do mais recente ao mais antigo (empate de data desfeito pelo `id`, de forma determinística), a janela  $W$  é construída com `LATEST_N = 10` e `MAX_PER_POLLSTER = 2`: tomam-se as 10 pesquisas mais recentes, varrendo do topo, pulando qualquer uma cujo instituto já ocupe 2 vagas na janela. O teto por instituto impede que uma casa que publica toda semana **carregue a média com o próprio efeito casa**. Há um **piso** `MIN_POLLS = 3`: se o teto deixar a janela com menos de 3 pesquisas, as puladas são readmitidas (mais recentes primeiro) até 3 (`capRelaxed`).

### 3.4 O consenso *leave-one-out* — `asOfAverage`

O consenso para  $c$  na data  $d$ , **excluindo o instituto**  $J$ , é a média dos valores de  $c$  na janela aplicada às pesquisas de  $\mathcal{P}_{-J}$  (todas em válidos) publicadas **até**  $d$ :

$$\bar{x}_{-J}(c, d) = \frac{1}{|V|} \sum_{p \in V} x_p(c), \quad V = \{p \in W(\text{selectWindow}) : x_p(c) \text{ existe}\}.$$

O consenso é **indefinido** (a célula ignora aquela data) se  $|V| < \text{MIN\_CONSENSUS\_POLLS} = 3$ : comparar contra "a média" quando só uma ou duas pesquisas testaram  $c$  é comparar contra ruído.

### 3.5 Resíduo, efeito casa e magnitude

Para cada pesquisa  $p$  de  $J$  (na data  $d$ ) que reporta  $c$  e para a qual o consenso existe, o **resíduo** é  $r_p(c) = x_p(c) - \bar{x}_{-J}(c, d)$ . O **efeito casa** de  $(J, c)$  é a média dos resíduos, exibida com 1 casa:

$$\text{efeito}(J, c) = \text{round}_1\left(\frac{1}{n} \sum_{i=1}^n r_i(c)\right) \quad n = \#\{\text{resíduos de } (J, c)\}.$$

A célula só é publicada se  $n \geq \text{MIN\_OBS\_PER\_CELL} = 2$ . A **magnitude** do instituto (que ordena as linhas) é  $\text{round}_1(\text{média}_c |\text{efeito}(J, c)|)$  sobre as células preenchidas. Um instituto entra na matriz apenas com  $\geq \text{MIN\_POLLS\_PER\_POLLSTER} = 3$  pesquisas na disputa.

### 3.6 As colunas

As colunas são os  $\text{MAX\_COLUMNS} = 6$  candidatos **registrados no TSE** de maior média no site (média oficial em votos válidos, `computeAverage`, filtrada pelo campo registrado de `candidaturas.ndjson`). Hoje: **Lula, Flávio Bolsonaro, Renan Santos, Ronaldo Caiado, Pablo Marçal, Zema**. (Coincide, portanto, com a base de medição dos resíduos: tudo em válidos.)

### 3.7 Parâmetros (confirmados lendo o código)

| Parâmetro                           | Valor   | Origem                       | Papel                                                  |
|-------------------------------------|---------|------------------------------|--------------------------------------------------------|
| <code>LATEST_N</code>               | 10      | <code>average.ts</code>      | tamanho da janela (nº de pesquisas)                    |
| <code>MAX_PER_POLLSTER</code>       | 2       | <code>average.ts</code>      | teto de pesquisas por instituto na janela              |
| <code>MIN_POLLS</code>              | 3       | <code>average.ts</code>      | piso de <i>backfill</i> quando o teto esvazia a janela |
| <code>MIN_POLLS_PER_POLLSTER</code> | 3       | <code>houseEffects.ts</code> | mínimo de pesquisas para o instituto entrar            |
| <code>MIN_OBS_PER_CELL</code>       | 2       | <code>houseEffects.ts</code> | mínimo de resíduos para a célula existir               |
| <code>MIN_CONSENSUS_POLLS</code>    | 3       | <code>houseEffects.ts</code> | mínimo de pesquisas de outros no consenso              |
| <code>MAX_COLUMNS</code>            | 6       | <code>houseEffects.ts</code> | nº de candidatos (colunas)                             |
| base                                | válidos | <code>houseEffects.ts</code> | <code>pollsFor(...).map(toBasis(p, "validos"))</code>  |

## 4. Por que votos válidos (o furo da base bruta)

Base bruta é a mesma **unidade** (% de respondentes), mas **não** a mesma base de comparação: cada instituto deixa uma fração distinta de indecisos/brancos fora dos nomes. Medida a "quão cheia" fica a base bruta (soma média dos % dos candidatos nomeados, por instituto):

| Instituto  | soma % nomeados | Instituto | soma % nomeados |
|------------|-----------------|-----------|-----------------|
| AtlasIntel | 95,7            | Gerp      | 83,0            |
| Datafolha  | 85,6            | Futura    | 81,5            |
| Paraná     | 85,6            | Quaest    | 81,0            |

A AtlasIntel espreme os indecisos: sua base bruta soma  $\approx 95,7$ , contra  $\approx 81\text{--}85$  dos demais. Na base bruta, **todo** candidato grande da AtlasIntel fica mecanicamente acima do consenso — e o maior candidato (Lula) recebe o maior empurrão absoluto. Isso **não** é "superestima o Lula"; é política de alocação de indecisos (que é *outro* efeito casa) contaminando o número.

Converter **os dois lados** a votos válidos remove o artefato. O impacto é material — recalculado pela nossa própria implementação, bruto  $\rightarrow$  válidos, nas 83 células:

- **3 células trocam de sinal** (ambos os lados  $\geq 0,5$  em módulo):

| Célula                     | bruto | válidos |
|----------------------------|-------|---------|
| AtlasIntel $\times$ Flávio | +1,6  | -2,4    |
| Quaest $\times$ Lula       | -2,3  | +0,7    |
| Nexus $\times$ Lula        | +0,7  | -0,8    |

- **18 das 83 células movem  $\geq 1,0$  p.p.** Destaques:

| Célula                     | bruto | válidos | leitura                               |
|----------------------------|-------|---------|---------------------------------------|
| AtlasIntel $\times$ Lula   | +10,5 | +5,6    | ~metade do +10,5 era artefato de base |
| AtlasIntel $\times$ Marçal | -6,2  | -8,7    | efeito real, ampliado                 |
| MDA $\times$ Flávio        | -5,6  | -3,9    | atenuado                              |
| Quaest $\times$ Flávio     | -2,9  | -0,5    | some                                  |

**Conclusão.** O efeito casa por candidato existe e é grande em vários institutos, mas sua magnitude — e às vezes o sinal — depende da base. Votos válidos é a base honesta: coloca instituto e consenso na mesma composição efetiva e mede o desvio **por candidato**, não a política de indecisos. É a base que o site agora publica.

## 5. Por que *leave-one-out* e os portões de robustez

**Leave-one-out.** Se o consenso incluísse as pesquisas do próprio  $J$ , a medição estaria contaminada por auto-comparação e o efeito seria **encolhido**, tanto mais quanto mais o instituto pesquisa. Formalmente, se  $J$  responde por uma fração  $w$  das pesquisas da janela com desvio verdadeiro  $\delta$ , um consenso **com**  $J$  mediria  $\approx (1 - w) \delta$ , subestimando  $\delta$ . A AtlasIntel tem 25 das 185 pesquisas ( $w \approx 0,14$ ): um consenso ingênuo mediria seu efeito em Lula perto de  $(1 - 0,14) \times 5,6 \approx 4,8$  em vez de 5,6 — e pior nas fases em que ela domina a janela. Excluir  $J$  é o que mantém a medição honesta.

**Portões** (cada um evita um modo de falha concreto):

- $\geq 3$  **pesquisas por instituto** — evita "efeitos" de 1–2 pesquisas, acaso amostral.

- $\geq 2$  **observações por célula** — um único resíduo não é tendência.
- $\geq 3$  **pesquisas de outros no consenso** — no início da série há poucas pesquisas; medir desvio contra uma média de 1 produz resíduos espúrios gigantes.
- **Teto de 2 por instituto na janela** — impede que uma casa prolífica domine o consenso.
- **Top-6 colunas registradas** — restringe a candidatos relevantes e registrados.

**Constraint da casa (leitura justa):** um instituto **ausente** da matriz (menos de 3 pesquisas, ou nenhuma célula com  $\geq 2$  observações) **não recebe juízo algum** — a ausência é falta de base, não avaliação.

---

## 6. Derivação passo a passo: AtlasIntel x Lula

---

A AtlasIntel tem **25 pesquisas** presidenciais de 1º turno. **24** têm valor de Lula e consenso definido; a 25ª (**2025-11-27**, id `da0d8d5a7034`) é um cenário **Tarcísio x Haddad** que **não testa Lula**, então é descartada por ausência do candidato (não por falta de consenso; e a pesquisa mais antiga, **2024-12-31**, **está** incluída). Abaixo, em votos válidos, cada pesquisa: o valor da AtlasIntel para Lula, o consenso das **demaís** pesquisas naquela data (janela `selectWindow`) e o resíduo.

| Data       | Atlas · Lula | Consenso sem Atlas | Resíduo |
|------------|--------------|--------------------|---------|
| 2024-12-31 | 44,73        | 45,325             | −0,591  |
| 2025-01-31 | 45,21        | 40,330             | +4,884  |
| 2025-02-27 | 43,33        | 38,612             | +4,722  |
| 2025-03-24 | 44,46        | 37,362             | +7,094  |
| 2025-04-24 | 46,47        | 37,130             | +9,341  |
| 2025-05-23 | 46,03        | 36,923             | +9,111  |
| 2025-06-30 | 46,75        | 38,641             | +8,109  |
| 2025-07-28 | 49,90        | 39,332             | +10,566 |
| 2025-08-25 | 45,79        | 39,920             | +5,875  |
| 2025-09-14 | 50,90        | 42,563             | +8,335  |
| 2025-10-19 | 50,36        | 41,942             | +8,419  |
| 2025-10-19 | 53,13        | 41,942             | +11,183 |
| 2025-12-10 | 48,83        | 43,005             | +5,823  |
| 2025-12-15 | 47,70        | 42,783             | +4,919  |
| 2025-12-15 | 48,83        | 42,783             | +6,045  |
| 2025-12-15 | 48,83        | 42,783             | +6,045  |
| 2026-01-20 | 47,79        | 43,021             | +4,765  |
| 2026-01-20 | 49,59        | 43,021             | +6,570  |
| 2026-02-24 | 48,11        | 45,392             | +2,718  |
| 2026-03-23 | 46,35        | 44,155             | +2,194  |
| 2026-04-27 | 44,47        | 44,416             | +0,050  |
| 2026-05-18 | 48,60        | 42,992             | +5,612  |
| 2026-06-30 | 46,86        | 46,041             | +0,821  |
| 2026-07-27 | 45,68        | 44,790             | +0,887  |

**Exemplo de uma linha (2026-01-20, resíduo +4,765).** Em votos válidos a AtlasIntel pôs Lula em 47,79 . O consenso sem AtlasIntel é a média de Lula nas 10 pesquisas mais recentes de **outros** institutos até 2026-01-20 (máx. 2 por casa) — 43,021. Resíduo = 47,79 − 43,021 = +4,77.

**Fechamento.** Média dos 24 resíduos = +5,562 ⇒ efeito = +5,6 p.p., exatamente o valor publicado. Desvio-padrão  $s = 3,26$ ; EP ingênuo  $s/\sqrt{24} = 0,67$ ; EP honesto por bootstrap de blocos = 0,87 (a série é autocorrelacionada, ver §8). Com o EP honesto,  $t = 5,56/0,87 \approx 6,4$  (df = 23) — o efeito está a ~6 erros-padrão de zero, inequivocamente real. (Na base bruta este número era +10,5; quase metade era artefato de alocação de indecisos — ver §4.)

## 7. Resultados completos e fidelidade

Matriz reproduzida (Python independente, `data/polls.json`, votos válidos). Cada célula: efeito em p.p. ( $\approx 0$  quando  $|\text{efeito}| < 0,5$ ; "—" sem base). Entre parênteses, o **EP honesto** (bootstrap de blocos quando  $n \geq 6$ , senão  $s/\sqrt{n}$ ) e o  $n$ ; \* = **significativo a 95%** pelo teste  $t(df)$  (§8). 185 pesquisas; 16 institutos; 83 células preenchidas.

| Instituto (n)          | Lula           | Flávio         | Renan         | Caiado         | Marçal        | Zema           |
|------------------------|----------------|----------------|---------------|----------------|---------------|----------------|
| AtlasIntel (25)        | +5,6* (0,9·24) | -2,4* (0,6·10) | +2,8* (0,5·7) | -0,5 (0,6·21)  | -8,7* (1,2·6) | -1,5* (0,3·20) |
| Gerp (19)              | -4,6* (1,0·16) | +4,8* (0,9·10) | -0,6 (0,4·9)  | -0,8 (0,4·19)  | -4,1* (0,7·5) | $\approx 0$    |
| Alfa/TMC (3)           | $\approx 0$    | -4,8* (0,4·3)  | -1,5* (0,2·3) | +2,7 (0,2·2)   | —             | +2,5 (0,9·3)   |
| Futura (18)            | -1,8* (0,8·14) | +6,3* (2,0·8)  | $\approx 0$   | +1,8* (0,6·16) | —             | $\approx 0$    |
| Paraná Pesquisas (20)  | -1,4 (0,7·12)  | +5,8 (2,1·3)   | -0,8* (0,1·3) | $\approx 0$    | —             | $\approx 0$    |
| Real Time Big Data (7) | $\approx 0$    | -2,0 (1,2·6)   | +1,9 (1,2·5)  | +2,0 (0,8·5)   | —             | +2,3 (1,5·7)   |
| Veritá (4)             | -3,3* (0,8·4)  | +3,4* (0,7·4)  | $\approx 0$   | -1,3* (0,1·4)  | —             | $\approx 0$    |
| MDA (8)                | -0,8 (2,1·8)   | -3,9* (0,2·3)  | -1,1 (0,5·3)  | -0,6 (0,4·7)   | —             | -1,1 (0,6·7)   |
| Data Index (3)         | +3,0* (0,3·3)  | -2,0 (0,8·3)   | -0,6 (0,4·3)  | +1,6* (0,3·3)  | —             | $\approx 0$    |
| Quaest (20)            | +0,7 (1,0·20)  | -0,5 (1,0·10)  | $\approx 0$   | -0,8 (0,4·17)  | +3,4 (1,7·2)  | -0,6* (0,3·17) |
| Ideia (8)              | +0,8 (0,7·8)   | +1,0 (0,9·6)   | -0,7* (0,3·8) | +1,4* (0,5·6)  | —             | $\approx 0$    |
| PoderData (5)          | -1,6* (0,5·5)  | +0,8 (0,7·5)   | +0,5 (0,6·5)  | -0,9* (0,3·5)  | —             | $\approx 0$    |
| 100% Cidades Part. (4) | -1,4 (2,9·3)   | +0,5 (1,6·4)   | $\approx 0$   | $\approx 0$    | —             | +1,7 (2,0·4)   |
| Datafolha (12)         | +0,7 (0,6·11)  | -1,1 (0,9·8)   | $\approx 0$   | +0,7 (0,7·11)  | —             | +0,9 (0,8·12)  |
| Vox (5)                | $\approx 0$    | -0,6 (1,0·5)   | -1,2* (0,3·5) | +1,2 (0,6·5)   | —             | $\approx 0$    |
| Nexus (10)             | -0,8* (0,3·10) | +0,5 (0,6·10)  | $\approx 0$   | $\approx 0$    | —             | $\approx 0$    |

(célula: efeito \* (EP·n); \* = signif. 95% por  $t(df)$ . " $\approx 0$ " quando  $|\text{efeito}| < 0,5$ .)

### 7.1 Fidelidade: a matriz reproduz o site — 100%

`verificar_fidelidade.py` é uma **implementação separada e autossuficiente** do algoritmo (não importa `reproduzir_efeito_casa.py`) que baixa o HTML **ao vivo** de `http://localhost:3000/institutos`, o parseia como fonte da verdade e compara célula a célula:

| Comparação                                          | Concordância   | Ordem das linhas |
|-----------------------------------------------------|----------------|------------------|
| Implementação independente × site AO VIVO (válidos) | 96/96 = 100,0% | idêntica         |

Nenhuma célula diverge. (O empate de arredondamento de 1,85 p.p. que existia na base bruta — **100% Cidades × Zema** — **desaparece** em votos válidos: a conversão desloca os resíduos e a média deixa de cair exatamente em x,x5. Não há mais qualquer célula na fronteira de arredondamento sensível à ordem de soma.)



## 8. Incerteza e significância

Para cada célula reportamos dois erros-padrão da média dos resíduos:

$$EP_{\text{ingênuo}} = \frac{s}{\sqrt{n}}, \quad EP_{\text{bloco}} = \text{sd das médias de reamostras por blocos móveis.}$$

O **EP ingênuo subestima** a incerteza porque os resíduos de um mesmo  $(J, c)$  **não são independentes**: janelas de consenso sobrepostas e opinião com tendência. Um **bootstrap de blocos móveis** (bloco  $\approx n^{1/3}$ ; determinístico dado o seed) capta essa autocorrelação. Nas células persistentes o EP honesto é  $\sim 20\text{--}33\%$  maior — p.ex. AtlasIntel×Lula  $0,67 \rightarrow 0,87$ ; Gerp×Lula  $0,74 \rightarrow 0,98$ . Usamos o **EP honesto** nas afirmações (e o bloco só é confiável para  $n \gtrsim 6$ ; para  $n$  pequeno vale o  $t$  sobre  $s/\sqrt{n}$ ).

**Teste.** Uma célula é **significativa a 95%** se, no teste  $t$  bicaudal de uma amostra ( $H_0$ : média dos resíduos = 0),  $|\bar{r}|/EP > t_{df, 0,975}$ , com  $df = n - 1$ . Isto **corrige** o critério plano  $|ef| > 2 EP$  do rascunho anterior, que ignorava o tamanho de amostra (para  $n = 3$ , o multiplicador correto é 4,30, não 2).

**Efeitos robustos** (amostra grande,  $n \geq 6$ , significativos com EP honesto):

| Instituto × candidato | Efeito | EP honesto | n  | t   |
|-----------------------|--------|------------|----|-----|
| AtlasIntel × Marçal   | −8,7   | 1,23       | 6  | 7,1 |
| Futura × Flávio       | +6,3   | 1,98       | 8  | 3,2 |
| AtlasIntel × Lula     | +5,6   | 0,87       | 24 | 6,4 |
| Gerp × Flávio         | +4,8   | 0,91       | 10 | 5,2 |
| Gerp × Lula           | −4,6   | 0,98       | 16 | 4,7 |
| AtlasIntel × Renan    | +2,8   | 0,52       | 7  | 5,4 |
| AtlasIntel × Flávio   | −2,4   | 0,56       | 10 | 4,4 |
| Futura × Caiado       | +1,8   | 0,60       | 16 | 2,9 |
| Futura × Lula         | −1,8   | 0,83       | 14 | 2,2 |
| AtlasIntel × Zema     | −1,5   | 0,25       | 20 | 6,2 |

**Efeitos apenas sugestivos** (amostra pequena,  $n \leq 5$ : o  $t$  pode passar, mas 3–4 resíduos podem produzir um EP artificialmente minúsculo e não sustentam magnitude precisa): Gerp×Marçal (−4,1,  $n = 5$ ), Alfa/TMC×Flávio (−4,8,  $n = 3$ ), MDA×Flávio (−3,9,  $n = 3$ ), Veritá×Lula/Flávio (−3,3/+3,4,  $n = 4$ ), Data Index×Lula (+3,0,  $n = 3$ ). O **signal** é informativo; a magnitude, não. **Não** citamos contagens do tipo "77 EP": com  $n = 3$  isso é estatisticamente vazio.

**Grandes, mas NÃO significativos a 95%** (correção importante face ao rascunho anterior):

**Paraná×Flávio** +5,8 ( $n = 3, t = 2,8 < 4,30$ ) e **Quaest×Marçal** +3,4 ( $n = 2, t = 2,0 < 12,71$ ) **não** são distinguíveis de zero a 95%. São sinais a acompanhar, não efeitos estabelecidos.

**Leitura.** Os destaques — AtlasIntel (Lula +5,6, Marçal −8,7, Flávio −2,4, Zema −1,5), Gerp (Lula −4,6, Flávio +4,8) e Futura×Flávio +6,3 — são robustos em base válidos e EP honesto. As muitas células  $\approx 0$  são o esperado de institutos sem viés detectável para aquele candidato: a matriz distingue viés de ruído.



## 9. Robustez / sensibilidade

Recalculamos os efeitos de destaque **em válidos**, variando a janela ( $LATEST\_N \in \{8, 10, 12\}$ ) e removendo o teto por instituto. Se fossem artefato de um parâmetro, mudariam de sinal ou de ordem de grandeza. Não mudam:

| Efeito (válidos)    | N=8  | N=10 (site) | N=12 | sem teto |
|---------------------|------|-------------|------|----------|
| AtlasIntel × Lula   | +5,5 | <b>+5,6</b> | +5,1 | +5,5     |
| AtlasIntel × Marçal | -7,8 | <b>-8,7</b> | -8,8 | -8,0     |
| AtlasIntel × Flávio | -2,7 | <b>-2,4</b> | -2,1 | -2,4     |
| Gerp × Lula         | -4,6 | <b>-4,6</b> | -4,8 | -4,7     |
| Gerp × Flávio       | +4,7 | <b>+4,8</b> | +4,9 | +4,8     |
| Futura × Flávio     | +6,0 | <b>+6,3</b> | +6,5 | +6,4     |
| MDA × Flávio        | -4,3 | <b>-3,9</b> | -3,9 | -3,9     |

Sinal e ordem de grandeza intactos nas quatro configurações; variação célula a célula  $\leq 0,9$  p.p. Os verificadores adversariais testaram ainda **janela por dias ( $\pm 30d$ )** e **ponderação por amostra** e reportaram estabilidade equivalente. A matriz não depende do valor exato de `LATEST_N` nem do teto.

## 10. Comparação com o estado da arte

Medir e publicar "house effects" é prática **padrão** e amplamente aceita:

- **FiveThirtyEight** publica *house effects* e *pollster ratings* há mais de uma década, como propriedade metodológica do instituto — não acusação.
- **The Economist** e outros modelos estimam desvios de instituto como parte natural do modelo (frequentemente bayesiano hierárquico).
- A literatura de *poll aggregation* formaliza o mesmo conceito como *pollster fixed effects* / *house effects*.

Nosso método é a versão **transparente e reproduzível** desse instrumento: regra única, pública, parâmetros à vista, base declarada (válidos) e código auditável — a versão **aberta** de um recurso que agregadores comerciais cobram.

## 11. Limitações honestas

- **Base (resolvido, mas com nuance).** Medir em válidos remove o artefato de alocação de indecisos — mas *quanto* de indeciso cada instituto distribui é, ele próprio, um efeito casa que esta matriz por candidato deliberadamente **não** exhibe. É uma escolha: isolar o lean por candidato.
- **Pool de cenários no 1º turno.** Todas as pesquisas de 1º turno entram num grupo; não separamos por cenário. Medido pelos verificadores: para AtlasIntel×Lula,  $\text{corr}(\text{nº de candidatos no cenário}, \text{resíduo}) = -0,52$  — parte do efeito é concentração de voto em elenco enxuto, não lean puro de casa.
- **Sem a dimensão modo de coleta.** Não separamos presencial/telefone/online, fonte conhecida e legítima de efeito casa. Parte do que atribuímos ao instituto pode ser do **modo**.

- **Média vs. mediana.** Usamos a média dos resíduos. Sob mediana, uma célula limítrofe (Futura×Flávio) encolhe — sinal de que poucos resíduos altos a puxam. As robustas de  $n$  grande não são sensíveis a isso.
- **EP e autocorrelação.** Mesmo o EP por blocos é aproximado; para  $n \leq 5$  nenhuma estimativa de EP é confiável, e nós rebaixamos essas células a "sugestivas".
- **Ausência ≠ juízo.** Um instituto fora da matriz não recebe avaliação.
- **Descritivo, não causal.** Um efeito casa **não** diz que o instituto está errado — a "verdade" só se conhece na eleição. Diz que ele desvia sistematicamente da média dos pares, em votos válidos.

## Apêndice de reprodutibilidade

**Endurecimento após revisão adversarial (25/08/2026).** Este método foi submetido a dois verificadores céticos independentes e revisto: **base votos válidos** (isola o viés por candidato), **significância por  $t(df)$**  (corrige o critério plano para  $n$  pequeno) e **EP por bootstrap de blocos** (corrige a subestimação por autocorrelação). Os grandes efeitos sobreviveram a todos os ataques em sinal e ordem de grandeza; onde uma célula deixou de ser significativa (Paraná×Flávio), o texto o diz.

**Como rodar** (Python 3, apenas biblioteca padrão — `json`, `statistics`, `math`, `random`, `urllib`):

```
# a partir da raiz do worktree pdp-staging (onde está data/polls.json):
python3 reproduzir_efeito_casa.py data/polls.json

# → imprime a matriz (válidos) e grava matriz_efeito_casa.csv com:
#     instituto, n_pesquisas, candidato, efeito, n_observacoes,
#     erro_padrao, erro_padrao_bloco, gl, t, significativo_95

# verificação de fidelidade INDEPENDENTE contra o site ao vivo (válidos):
python3 verificar_fidelidade.py data/polls.json

# → CONCORDÂNCIA (implementação independente vs site): 96/96 = 100,0%
```

**Arquivos entregues** (nesta pasta):

- `reproduzir_efeito_casa.py` — reimplementação independente (stdlib), base válidos, com  $t(df)$  e EP por bootstrap de blocos; gera a matriz e o CSV.
- `verificar_fidelidade.py` — 3ª implementação autossuficiente (não importa a anterior); parseia o HTML ao vivo de `/institutos` e compara célula a célula.
- `matriz_efeito_casa.csv` — matriz completa (válidos) com efeito,  $n$ , EP ingênuo, EP por bloco,  $gl$ ,  $t$  e veredito de significância 95%.
- `site_efeito_casa.json` — snapshot da tabela publicada (válidos), usado como *fallback*.
- `efeito-casa-metodologia.md` — este documento.

**Fonte dos dados.** Curadoria de fontes públicas (agregador Poder360, páginas de pesquisas da Wikipédia) reconciliada com o **registro de pesquisas do TSE** (Dados Abertos — PesqEle 2026). Cada pesquisa carrega seu `tse_registration` e `integra_url`.

**Proveniência do arquivo usado.**

- Arquivo: `data/polls.json`

- SHA-256: `885128c7f722def57e63a28a8855e35cc98323edb45976b3bbf5ae25eb949911`
- `generated_at` do store: `2026-08-23T12:59:35Z` (schema v2). A alteração para votos válidos foi **no código** (`houseEffects.ts`), não nos dados — o SHA do `polls.json` permanece o mesmo do rascunho em base bruta.
- Disputa: `race="presidente"`, `state=null`, `round=1` — 185 pesquisas.
- Relatório gerado em: **2026-08-25**. Python 3.9.6.

```
shasum -a 256 data/polls.json  
# 885128c7f722def57e63a28a8855e35cc98323edb45976b3bbf5ae25eb949911
```

Qualquer pessoa com o `polls.json` deste SHA e os dois scripts obtém, sem dependências externas, exatamente a matriz aqui documentada.